

Optimización Híbrida GWO–MFO y Bayesiana de XGBoost para Predicción de Incumplimiento Crediticio en Datos Desbalanceados

Lenin Francisco López Cabrera

Facultad de Ingeniería
Ciencia de Datos e Inteligencia Artificial
Universidad Nacional de Chimborazo
Riobamba, Ecuador
leninf.lopez@unach.edu.ec

Jose Mario Camacho Monar

Facultad de Ingeniería
Ciencia de Datos e Inteligencia Artificial
Universidad Nacional de Chimborazo
Riobamba, Ecuador
mario.camacho@unach.edu.ec

Brayan Gualberto Cárdenas Medina

Facultad de Ingeniería
Ciencia de Datos e Inteligencia Artificial
Universidad Nacional de Chimborazo
Riobamba, Ecuador
brayan.cardenas@unach.edu.ec

Dennys Alexander Becerra Gavidia

Facultad de Ingeniería
Ciencia de Datos e Inteligencia Artificial
Universidad Nacional de Chimborazo
Riobamba, Ecuador
dennys.becerra@unach.edu.ec

Dennis Iván Sánchez Palomo

Facultad de Ingeniería
Ciencia de Datos e Inteligencia Artificial
Universidad Nacional de Chimborazo
Riobamba, Ecuador
dennis.sanchez@unach.edu.ec

Resumen—La predicción del incumplimiento crediticio es una tarea crítica en la gestión del riesgo financiero, particularmente desafiante cuando los conjuntos de datos presentan un desbalance severo de clases. Este estudio presenta un análisis comparativo exhaustivo de estrategias de optimización de hiperparámetros para el clasificador eXtreme Gradient Boosting (XGBoost) aplicado al dataset UCI Credit Card Default (30 000 instancias, 23 características, $\approx 22.1\%$ clase positiva). Se evalúan cinco enfoques bajo presupuestos computacionales controlados: (i) Grey Wolf Optimizer (GWO) con 15 y 30 iteraciones, (ii) una estrategia híbrida de relevo GWO–Moth-Flame Optimization (MFO) con configuraciones (8+7) y (21+9) que combina exploración global con explotación local, y (iii) optimización bayesiana mediante Optuna con 800 y 1400 trials. Todos los modelos se evalúan utilizando el área bajo la curva Precision–Recall (PR-AUC) como métrica principal, complementada con ROC-AUC, F1-score, recall y exactitud. Una función de aptitud basada en la media geométrica $\sqrt{\text{PR-AUC} \times F_1}$ con restricción de suelo en recall ($R \geq 0.55$) y factor de penalización $\lambda = 0.8$ guía la búsqueda metaheurística. La robustez se verifica mediante 10 ejecuciones independientes por configuración con semillas aleatorias distintas, y la significancia estadística se confirma mediante la prueba de Wilcoxon con corrección de Holm–Bonferroni ($p < 0.05$) y verificación de normalidad Shapiro–Wilk. Los resultados demuestran que el híbrido GWO(21)+MFO(9) alcanza el PR-AUC medio más alto de 0.5520 (+1.56 % sobre el modelo base), mientras que Optuna (1400 trials) alcanza 0.5543 (+1.55 %). Ambos enfoques producen mejoras estadísticamente

significativas sobre el modelo base tras la corrección por comparaciones múltiples. Notablemente, la fase de refinamiento MFO no aporta una mejora estadísticamente significativa sobre GWO puro ($p > 0.21$), un resultado negativo honesto que se analiza en detalle. Se discute el techo inherentemente limitado de las métricas predictivas en scoring crediticio bajo desbalance de clases y se contextualizan los hallazgos dentro de la literatura más amplia.

Palabras clave—XGBoost, Grey Wolf Optimizer, Moth-Flame Optimization, optimización bayesiana, Optuna, desbalance de clases, PR-AUC, predicción de incumplimiento crediticio, metaheurísticas bioinspiradas, sintonización de hiperparámetros.

Abstract—Credit default prediction is a critical task in financial risk management, particularly challenging when datasets exhibit severe class imbalance. This study presents a comprehensive comparative analysis of hyperparameter optimization strategies for the eXtreme Gradient Boosting (XGBoost) classifier applied to the UCI Credit Card Default dataset (30 000 instances, 23 features, $\approx 22.1\%$ positive class). We evaluate five optimization approaches under controlled computational budgets: (i) Grey Wolf Optimizer (GWO) with 15 and 30 iterations, (ii) a two-phase hybrid GWO–Moth-Flame Optimization (MFO) relay strategy with configurations (8+7) and (21+9) combining global exploration with local exploitation, and (iii) Bayesian optimization via Optuna with 800 and 1400 trials. All models are assessed using the Precision–Recall Area Under the Curve (PR-AUC) as the primary metric, supplemented by ROC-AUC, F1-score, recall,

and accuracy. A geometric-mean fitness function $\sqrt{\text{PR-AUC} \times F_1}$ with a recall floor constraint ($R \geq 0.55$) and penalty factor $\lambda = 0.8$ guides the metaheuristic search. Robustness is verified through 10 independent executions per configuration with distinct random seeds, and statistical significance is confirmed via the Wilcoxon signed-rank test with Holm–Bonferroni correction ($p < 0.05$) and Shapiro–Wilk normality verification. Results demonstrate that the hybrid GWO(21)+MFO(9) achieves the highest mean PR-AUC of 0.5520 (+1.56 % over the baseline), while Optuna (1 400 trials) reaches 0.5543 (+1.55 %). Both approaches yield statistically significant improvements over the baseline after multiple-comparison correction. Notably, the MFO refinement phase does not contribute a statistically significant improvement over GWO alone ($p > 0.21$), an honest negative result that we analyze in detail. We discuss the inherently limited ceiling of predictive metrics in credit scoring under class imbalance, contextualize our findings within the broader literature, and provide transparent declarations of methodological limitations.

Index Terms—XGBoost, Grey Wolf Optimizer, Moth-Flame Optimization, Bayesian optimization, Optuna, class imbalance, PR-AUC, credit default prediction, bioinspired metaheuristics, hyperparameter tuning.

I. INTRODUCCIÓN

LA predicción del incumplimiento crediticio constituye uno de los problemas más relevantes en la gestión del riesgo financiero contemporáneo. Las instituciones bancarias y financieras dependen de modelos predictivos precisos para estimar la probabilidad de que un prestatario incumpla sus obligaciones, lo cual impacta directamente en la asignación de capital regulatorio bajo los acuerdos de Basilea III [30]. La literatura ha documentado extensamente que los errores de clasificación en este dominio tienen costos asimétricos: un falso negativo (no detectar un incumplimiento) puede resultar en pérdidas financieras significativas que afectan la solvencia institucional, mientras que un falso positivo (rechazar un cliente solvente) implica una oportunidad de negocio perdida y una pérdida de competitividad en el mercado [17], [18].

El algoritmo eXtreme Gradient Boosting (XGBoost) [1] se ha consolidado como una de las técnicas de aprendizaje supervisado más eficaces para problemas de clasificación tabular, gracias a su regularización integrada (L1 y L2), manejo nativo de valores faltantes mediante dirección de aprendizaje (*sparsity-aware*), capacidad de paralelización a nivel de bloques y podado de árboles basado en profundidad [2]. No obstante, el rendimiento de XGBoost depende críticamente de la configuración de sus hiperparámetros—tales como la tasa de aprendizaje, la profundidad máxima de los árboles y el número de estimadores—, cuya selección manual resulta ineficiente en espacios de búsqueda de alta dimensionalidad [7]. Alternativas como LightGBM [31] y CatBoost [32] ofrecen ventajas en velocidad de entrenamiento y manejo de variables categóricas, respectivamente, pero XGBoost sigue siendo el referente en benchmarks de scoring crediticio por su equilibrio entre rendimiento y generalización [16].

La optimización de hiperparámetros mediante algoritmos metaheurísticos bioinspirados ha emergido como una alternativa viable frente a las estrategias de búsqueda aleatoria [7] y la optimización bayesiana [6]. El Grey Wolf Optimizer (GWO) [3], inspirado en la jerarquía social y las

estrategias de caza cooperativa de los lobos grises (*Canis lupus*), ofrece un equilibrio entre exploración y explotación con pocos parámetros de control. El Moth-Flame Optimization (MFO) [4], basado en la navegación transversal de las polillas hacia fuentes de luz mediante trayectorias espirales logarítmicas, proporciona una capacidad de refinamiento local notable en espacios continuos. La hibridación secuencial de metaheurísticas—exploración global seguida de explotación local—ha sido documentada como una técnica efectiva para evitar óptimos locales y mejorar la convergencia [20], [21], aunque su aplicación específica a la sintonización de XGBoost en scoring crediticio no ha sido explorada en profundidad.

Paralelamente, la optimización bayesiana implementada en frameworks como Optuna [5] utiliza modelos sustitutos basados en el algoritmo Tree-structured Parzen Estimator (TPE) [8] para guiar la búsqueda de manera más eficiente en términos de evaluaciones de la función objetivo (OFEs) [6]. La comparación entre enfoques bioinspirados y bayesianos bajo presupuestos computacionales equivalentes constituye una línea de investigación activa [29], particularmente relevante cuando los recursos computacionales son limitados.

Un desafío adicional e ineludible en la predicción crediticia es el desbalance de clases. En el dataset UCI Credit Card Default [15], aproximadamente el 22.1 % de las instancias corresponden a incumplimiento (clase positiva), lo que genera un sesgo sistemático hacia la clase mayoritaria y degrada las métricas tradicionales como la exactitud [9]. En este contexto, el área bajo la curva Precision–Recall (PR-AUC) se considera más informativa que ROC-AUC, ya que no se ve inflada por la predominancia de verdaderos negativos [11], [12].

Las contribuciones principales de este trabajo son:

- Se implementa y evalúa una estrategia híbrida de relevancia GWO–MFO para la optimización de hiperparámetros de XGBoost en scoring crediticio, comparándola con GWO puro y con optimización bayesiana (Optuna) bajo presupuestos de OFEs equivalentes (900 y 1 800). Se analiza honestamente que la fase MFO no aporta mejora estadísticamente significativa sobre GWO en este problema específico.
- Se diseña una función de aptitud basada en la media geométrica de PR-AUC y F1-score, $\sqrt{\text{PR-AUC} \times F_1}$, con una restricción de suelo en recall ($R \geq 0.55$) y penalización proporcional ($\lambda = 0.8$), adecuada para datos desbalanceados.
- Se realiza un análisis de robustez con 10 ejecuciones independientes por configuración, se verifica la normalidad mediante Shapiro–Wilk, y se confirma la significancia estadística mediante la prueba de Wilcoxon con corrección de Holm–Bonferroni para comparaciones múltiples.
- Se contextualizan los resultados dentro de la literatura existente, discutiendo las limitaciones inherentes de las métricas predictivas en problemas de scoring crediticio con desbalance severo, incluyendo una declaración transparente de las limitaciones metodológicas del estudio.

El resto del artículo se organiza de la siguiente manera: la Sección II revisa los trabajos relacionados; la Sección III describe la metodología; la Sección IV presenta los resultados experimentales; la Sección V discute los hallazgos en

comparación con la literatura; y la Sección VI expone las conclusiones y líneas de trabajo futuro.

II. TRABAJOS RELACIONADOS

II-A. Predicción de Incumplimiento Crediticio

La modelización del riesgo crediticio ha evolucionado significativamente desde los modelos clásicos de regresión logística y análisis discriminante lineal [17], [18] hacia técnicas de aprendizaje automático más complejas y no lineales. Lessmann *et al.* [16] realizaron un benchmark exhaustivo de 41 algoritmos de clasificación sobre ocho datasets crediticios reales, concluyendo que los métodos de ensemble—particularmente Random Forest y Gradient Boosting—superan consistentemente a los modelos lineales en términos de capacidad discriminativa. Yeh y Lien [15] introdujeron el dataset UCI Credit Card Default, que se ha convertido en un referente estándar para la evaluación de técnicas de scoring crediticio. Brown y Taylor [19] demostraron empíricamente que la deuda de los hogares está influenciada por factores demográficos, financieros y comportamentales, lo que justifica el uso de variables como historial de pagos, límites de crédito y montos de facturación como predictores del incumplimiento.

II-B. Optimización de Hiperparámetros con Metaheurísticas

La aplicación de algoritmos bioinspirados para la sintonización de modelos de aprendizaje automático ha ganado tracción significativa en la última década. Mirjalili *et al.* [3] propusieron GWO, que ha sido aplicado exitosamente a la optimización de máquinas de vectores de soporte (SVM) [25], redes neuronales multicapa [26] y modelos de ensemble. El MFO [4] ha demostrado eficacia en problemas de ingeniería con espacios de búsqueda continuos y multimodales. La hibridación de metaheurísticas, particularmente en estrategias de dos fases (exploración global seguida de explotación local), ha sido documentada como una técnica efectiva para evitar óptimos locales y mejorar la calidad de las soluciones [20], [21]. Kennedy y Eberhart [23] sentaron las bases de la inteligencia de enjambre con la Optimización por Enjambre de Partículas (PSO), y Dorigo *et al.* [24] introdujeron la optimización por colonia de hormigas, ambos precursores conceptuales de GWO y MFO. El teorema *No Free Lunch* [22] establece que ningún algoritmo de optimización es universalmente superior, lo que motiva la exploración de estrategias híbridas.

II-C. Optimización Bayesiana y Optuna

La optimización bayesiana [6] utiliza un modelo sustituto (generalmente un proceso gaussiano o TPE) para aproximar la función objetivo y una función de adquisición para decidir el siguiente punto a evaluar, logrando una exploración eficiente del espacio de búsqueda. Bergstra *et al.* [8] propusieron el algoritmo TPE, que modela $p(\mathbf{x}|y)$ y $p(y)$ de forma separada, ofreciendo ventajas computacionales sobre los procesos gaussianos en espacios de alta dimensionalidad. Bergstra y Bengio [7] demostraron empíricamente que la búsqueda aleatoria supera a la búsqueda en cuadrícula en espacios de alta dimensionalidad, estableciendo un punto de referencia

para la evaluación de métodos de optimización. Optuna [5] implementa TPE y ofrece un framework flexible con poda automática de trials no prometedores, paralelización nativa y soporte para espacios de búsqueda condicionales. Hutter *et al.* [29] proporcionaron el marco teórico de la optimización secuencial basada en modelos (SMBO), que unifica estos enfoques bajo un formalismo común.

II-D. Manejo de Datos Desbalanceados

He y Garcia [9] proporcionaron una revisión comprehensiva de las técnicas para aprendizaje con datos desbalanceados, categorizándolas en métodos a nivel de datos (sobremuestreo como SMOTE [10], submuestreo), métodos a nivel de algoritmo (como `scale_pos_weight` y funciones de costo sensibles) y métodos a nivel de evaluación (métricas específicas). Davis y Goadrich [11] argumentaron formalmente que PR-AUC es más informativa que ROC-AUC en escenarios desbalanceados, demostrando que una optimización en el espacio ROC no garantiza una optimización equivalente en el espacio PR. Saito y Rehmsmeier [12] formalizaron esta recomendación para problemas binarios con prevalencia baja, mostrando que ROC-AUC puede presentar valores engañosamente altos. Fawcett [13] estableció las bases del análisis ROC y las curvas de convexidad, mientras que Powers [14] analizó las relaciones matemáticas entre las distintas métricas de evaluación, incluyendo las medidas de informedness y markedness.

III. METODOLOGÍA

La Fig. 1 ilustra el pipeline experimental completo del estudio.

III-A. Conjunto de Datos y Desbalance de Clases

Se emplea el dataset *Default of Credit Card Clients* del repositorio UCI [15], que contiene 30 000 registros de clientes de tarjetas de crédito en Taiwán (abril–septiembre de 2005). El conjunto incluye 23 variables predictoras: límite de crédito, sexo, educación, estado civil, edad, historial de pagos (6 meses: X_1 – X_6), montos de facturación (6 meses: X_7 – X_{12}) y montos de pago previo (6 meses: X_{13} – X_{18}). La variable objetivo es binaria: incumplimiento en el mes siguiente (1) o cumplimiento (0).

Desbalance de clases: La distribución presenta un desbalance significativo: 23 364 instancias de cumplimiento (77.9 %) frente a 6 636 de incumplimiento (22.1 %), con una ratio de desbalance de aproximadamente 3.52:1. Este desbalance implica que un clasificador trivial que prediga siempre la clase mayoritaria alcanzaría una exactitud del 77.9 %, lo que invalida la exactitud como métrica principal de evaluación y motiva el uso de PR-AUC como criterio de optimización [9], [11], [12].

III-B. Preprocesamiento y División

Los datos se dividen en conjuntos de entrenamiento (80 %, 24 000 instancias: 18 691 clase 0, 5 309 clase 1) y prueba (20 %, 6 000 instancias) mediante división estratificada (`stratify=y`) para preservar la proporción de clases en




Figura 1. Diagrama del pipeline experimental. Todos los métodos se evalúan con el mismo protocolo de validación y presupuesto computacional controlado.

ambos subconjuntos. La semilla aleatoria global se fija en 42 para garantizar reproducibilidad. No se aplica normalización ni codificación adicional, dado que XGBoost maneja nativamente variables numéricas y categóricas ordinales mediante divisiones basadas en histogramas [1].

III-C. Manejo del Desbalance de Clases

Para contrarrestar el efecto del desbalance, se emplean dos estrategias complementarias:

1) **Ponderación de clases (scale_pos_weight):** Se calcula como:

$$w = \frac{N_{\text{neg}}}{N_{\text{pos}}} = \frac{18\,691}{5\,309} \approx 3,5206 \quad (1)$$

donde N_{neg} y N_{pos} son el número de instancias de la clase mayoritaria y minoritaria en el conjunto de entrenamiento. Este peso multiplica la contribución del gradiente de los errores en la clase positiva durante el entrenamiento, penalizando más los falsos negativos [1], [9].

2) **Optimización del peso como hiperparámetro:** Adicionalmente, `scale_pos_weight` se incorpora como hiperparámetro a optimizar dentro del rango $[2,0,5,0]$, permitiendo que los algoritmos de optimización ajusten dinámicamente el grado de penalización según la configuración de los demás parámetros.

III-D. Métricas de Evaluación

Dado el desbalance de clases ($\pi \approx 0,22$), se seleccionan métricas que no se vean distorsionadas por la predominancia de la clase mayoritaria [9], [11], [12]. A continuación se definen formalmente todas las métricas empleadas:

III-D1. **Matriz de Confusión:** La base de todas las métricas es la matriz de confusión, que tabula cuatro cantidades fundamentales: verdaderos positivos (TP), falsos positivos (FP), verdaderos negativos (TN) y falsos negativos (FN), donde $TP + FP + TN + FN = N$.

III-D2. **Exactitud (Accuracy):**

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

Se reporta como referencia contextual, pero **no** se utiliza como criterio de optimización debido a su insensibilidad al desbalance: con $\pi = 0,22$, un clasificador trivial alcanza $\text{Acc} = 0,78$ [9].

III-D3. **Precisión (Precision):**

$$P = \frac{TP}{TP + FP} \quad (3)$$

Mide la proporción de predicciones positivas que son correctas, es decir, la fiabilidad de las alertas de incumplimiento emitidas por el modelo [17].

III-D4. **Sensibilidad (Recall):**

$$R = \frac{TP}{TP + FN} \quad (4)$$

Cuantifica la capacidad del modelo para identificar correctamente los incumplimientos reales. En el contexto crediticio, un recall bajo implica que un porcentaje significativo de morosos potenciales no son detectados [18].

III-D5. **Puntaje F1 (F1-Score):**

$$F_1 = 2 \cdot \frac{P \cdot R}{P + R} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN} \quad (5)$$

Media armónica entre precisión y recall que penaliza los valores extremos [14]. Un F1 bajo indica que el modelo no logra un equilibrio adecuado entre detectar morosos y evitar falsas alarmas.

III-D6. **Área bajo la Curva Precision-Recall (PR-AUC):**

$$\text{PR-AUC} = \sum_n (R_n - R_{n-1}) \cdot P_n \quad (6)$$

donde P_n y R_n son la precisión y el recall en el n -ésimo umbral de decisión, calculada mediante `average_precision_score` de scikit-learn. A diferencia de ROC-AUC, PR-AUC no se ve inflada por los verdaderos negativos y es más informativa cuando la clase positiva es minoritaria [11], [12]. Se adopta como **métrica principal** de este estudio.

III-D7. **Área bajo la Curva ROC (ROC-AUC):**

$$\text{ROC-AUC} = \int_0^1 \text{TPR}(\text{FPR}) d(\text{FPR}) \quad (7)$$

donde $\text{TPR} = R$ (tasa de verdaderos positivos) y $\text{FPR} = FP/(FP + TN)$ (tasa de falsos positivos). Se incluye como métrica complementaria [13].

III-D8. **Media Geométrica (Geo-Mean):**

$$G = \sqrt{\text{PR-AUC} \times F_1} \quad (8)$$

Se utiliza como función de aptitud combinada en la optimización para evitar la degeneración hacia una sola métrica [9].

III-E. Justificación de la Selección de Métricas

La elección de PR-AUC como métrica principal se fundamenta en tres argumentos técnicos:

1) Insensibilidad de ROC-AUC al desbalance: Con prevalencia $\pi \approx 0,22$, ROC-AUC puede alcanzar valores aparentemente altos ($>0,75$) incluso con modelos mediocres, debido a la abundancia de verdaderos negativos que inflan la especificidad [12]. Davis y Goadrich [11] demostraron formalmente que una mejora en ROC-AUC no implica necesariamente una mejora equivalente en PR-AUC.

2) Relevancia operativa: PR-AUC refleja directamente el compromiso entre la capacidad de detectar morosos (recall) y la fiabilidad de las alertas (precisión), que es la decisión operativa relevante para una entidad financiera [17], [18].

3) Consenso en la literatura: La literatura en scoring crediticio recomienda explícitamente PR-AUC sobre ROC-AUC en contextos desbalanceados [9], [12], [16].

III-F. Modelo Base: XGBoost

XGBoost [1] es una implementación regularizada del algoritmo de gradient boosting [2] que minimiza una función objetivo regularizada:

$$\mathcal{L} = \sum_{i=1}^N l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad (9)$$

donde $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2$ penaliza la complejidad del modelo (T : número de hojas, $\mathbf{w}$: pesos de las hojas). El modelo base se configura con: `n_estimators=500`, `max_depth=6`, `learning_rate=0.05`, `subsample=0.8`, `colsample_bytree=0.8`, `scale_pos_weight=3.5206`, `tree_method=hist`, `device=cuda`.

III-G. Optimización con Grey Wolf Optimizer (GWO)

GWO [3] simula la jerarquía de manada (α , β , δ , ω) y las fases de caza (búsqueda, cerco y ataque):

$$\mathbf{D} = |\mathbf{C} \cdot \mathbf{X}_p(t) - \mathbf{X}(t)| \quad (10)$$

$$\mathbf{X}(t+1) = \mathbf{X}_p(t) - \mathbf{A} \cdot \mathbf{D} \quad (11)$$

donde $\mathbf{A} = 2\mathbf{a} \cdot \mathbf{r}_1 - \mathbf{a}$ (con $\mathbf{a}$ decreciente linealmente de 2 a 0) controla la exploración/explotación, y $\mathbf{C} = 2\mathbf{r}_2$ introduce aleatoriedad [3]. La posición final se promedia entre las tres mejores soluciones (α , β , δ):

$$\mathbf{X}(t+1) = \frac{\mathbf{X}_1 + \mathbf{X}_2 + \mathbf{X}_3}{3} \quad (12)$$

Cada lobo codifica un vector de seis hiperparámetros. Se configuran dos escenarios: GWO-15 (15 épocas, población 20, 900 OFEs) y GWO-30 (30 épocas, población 20, 1 800 OFEs).

III-H. Optimización con Moth-Flame Optimization (MFO)

MFO [4] modela la navegación transversal de las polillas mediante trayectorias espirales logarítmicas:

$$S(M_i, F_j) = D_i \cdot e^{bt} \cdot \cos(2\pi t) + F_j \quad (13)$$

donde $D_i = |F_j - M_i|$ es la distancia a la llama, b controla la forma de la espiral y $t \in [-1, 1]$ [4]. El número de llamas decrece adaptativamente:

$$\text{flame_no} = \text{round} \left(N - l \cdot \frac{N-1}{T} \right) \quad (14)$$

donde l es la iteración actual y T el total de iteraciones.

III-I. Estrategia Híbrida GWO-MFO (Relevo)

Se propone una estrategia de dos fases que explota la complementariedad de ambos algoritmos [21], [22]:

- Fase 1 – Exploración global (GWO):** Se ejecuta GWO con E_G épocas y población $P = 20$.
- Fase 2 – Explotación local (MFO):** Se toma la mejor solución $\mathbf{x}^*$ del GWO y se define un subespacio local:

$$\text{LB}_i^{\text{loc}} = \max(\text{LB}_i, x_i^* - 0,20 \cdot (\text{UB}_i - \text{LB}_i)) \quad (15)$$

$$\text{UB}_i^{\text{loc}} = \min(\text{UB}_i, x_i^* + 0,20 \cdot (\text{UB}_i - \text{LB}_i)) \quad (16)$$

MFO opera E_M épocas con población 20 en este subespacio restringido.

Se evalúan dos configuraciones con OFEs equivalentes a GWO: Híbrido (8+7) con 900 OFEs y Híbrido (21+9) con 1 800 OFEs.

III-J. Optimización Bayesiana con Optuna

Optuna [5] implementa TPE [8] que modela la distribución de hiperparámetros condicionada al rendimiento:

$$p(\mathbf{x}|\mathbf{y}) = \begin{cases} l(\mathbf{x}) & \text{si } \mathbf{y} < \mathbf{y}^* \\ g(\mathbf{x}) & \text{si } \mathbf{y} \geq \mathbf{y}^* \end{cases} \quad (17)$$

La función de adquisición maximiza la ratio $l(\mathbf{x})/g(\mathbf{x})$. Se configuran: Escenario A (800 trials, 900 OFEs con CV-3) y Escenario B (1 400 trials, 1 800 OFEs con CV-3).

III-K. Función de Aptitud

Para la optimización metaheurística se emplea:

$$\text{fitness} = 1 - \sqrt{\text{PR-AUC}_{\text{CV}} \times F_{1,\text{CV}}} \quad (18)$$

con penalización si $R_{\text{CV}} < R_{\text{mín}} = 0,55$:

$$\text{fitness}_{\text{pen}} = \text{fitness} + \lambda \cdot \max(0, R_{\text{mín}} - R_{\text{CV}}) \quad (19)$$

donde $\lambda = 0,8$ [9]. La misma función objetivo se utiliza en Optuna (maximizando $\sqrt{\text{PR-AUC} \times F_1}$ – penalización).

III-L. Espacio de Búsqueda

La Tabla I define el espacio de búsqueda común para todos los métodos.

III-M. Análisis de Robustez y Significancia Estadística

Se realizan 10 ejecuciones independientes con semillas {42, 123, 456, 789, 1011, 1213, 1415, 1617, 1819, 2021}. La normalidad se verifica mediante la prueba de Shapiro-Wilk [27]. La significancia se evalúa mediante la prueba de rangos con signo de Wilcoxon unilateral [27], [28] con corrección de Holm-Bonferroni para comparaciones múltiples ($\alpha = 0,05$). Se reportan intervalos de confianza del 95 % basados en la distribución t de Student.

Cuadro I
ESPACIO DE BÚSQUEDA DE HIPERPARÁMETROS PARA XGBOOST.

Hiperparámetro	Inf.	Sup.	Tipo
n_estimators	100	600	Entero
max_depth	3	10	Entero
learning_rate	0.01	0.15	Log-uniforme
subsample	0.6	1.0	Uniforme
colsample_bytree	0.6	1.0	Uniforme
scale_pos_weight	2.0	5.0	Uniforme

III-N. Entorno Computacional

Todos los experimentos se ejecutan en Kaggle con GPU NVIDIA (CUDA habilitado), XGBoost 3.2.0, Python 3.12, Optuna y Mealy 3.3.0 (GWO, MFO). El tiempo total de experimentación fue de aproximadamente 7.2 horas (4.24 h para GWO-MFO y 2.93 h para Optuna).

IV. RESULTADOS EXPERIMENTALES

IV-A. Modelo Base

La Fig. 2 presenta la evaluación del modelo base XGBoost con configuración por defecto.

IV-B. Resultados de GWO

Las Figs. 3 y 4 presentan los resultados de GWO con 15 y 30 iteraciones, respectivamente.

IV-C. Resultados del Híbrido GWO-MFO

Las Figs. 5 y 6 presentan los resultados de la estrategia híbrida.

IV-D. Resultados de Optuna

Las Figs. 7 y 8 presentan los resultados de la optimización bayesiana.

IV-E. Convergencia de Optuna

La Fig. 9 muestra la curva de convergencia de la optimización bayesiana.

IV-F. Tabla Comparativa de Rendimiento

La Tabla II consolida todas las métricas de evaluación. La Tabla III presenta los hiperparámetros óptimos encontrados por cada método.

IV-G. Matrices de Confusión

La Tabla IV detalla las matrices de confusión en el conjunto de prueba (6000 instancias).

IV-H. Análisis de Robustez

Las Figs. 10 y 11 muestran la distribución de PR-AUC en 10 ejecuciones independientes.

IV-I. Análisis Estadístico

La Tabla V resume los intervalos de confianza y la verificación de normalidad.

La prueba de Shapiro-Wilk confirma normalidad para el modelo base ($W = 0,9633$, $p = 0,8231 > 0,05$), validando el uso de pruebas paramétricas complementarias. La prueba de Wilcoxon con corrección de Holm-Bonferroni confirma que todos los métodos optimizados superan significativamente al modelo base ($p_{\text{Holm}} < 0,05$), mientras que las diferencias entre métodos optimizados no alcanzan significancia estadística ($p_{\text{Holm}} > 0,21$).

IV-J. Resumen de Tiempos Computacionales

La Tabla VI presenta los tiempos de ejecución.

V. DISCUSIÓN

V-A. Interpretación de las Métricas en Contexto Desbalanceado

Los valores de PR-AUC obtenidos (0.54–0.56) deben interpretarse a la luz del desbalance inherente del problema. Con prevalencia $\pi = 0,22$, la línea base aleatoria (clasificador que predice la clase positiva con probabilidad π) produce $\text{PR-AUC} \approx \pi = 0,22$ [11]. Un PR-AUC de 0.5543 representa aproximadamente $2.5\times$ sobre el azar, lo cual es consistente con los resultados reportados por Lessmann *et al.* [16], quienes documentan PR-AUC en el rango 0.40–0.60 para los mejores algoritmos de su benchmark de 41 clasificadores sobre datasets crediticios.

Es fundamental comprender que un PR-AUC de 0.55 **no** indica un modelo deficiente, sino que refleja la dificultad intrínseca del problema de predicción de incumplimiento. La literatura en scoring crediticio ha establecido que la predictibilidad del incumplimiento está inherentemente limitada por factores exógenos no observables: cambios en la situación laboral, eventos de salud, crisis económicas sectoriales y cambios regulatorios [18], [19]. Hand y Henley [17] señalan que la predictibilidad está limitada por la naturaleza estocástica del comportamiento financiero humano, y que incluso los modelos más sofisticados no pueden capturar la totalidad de la varianza en el incumplimiento.

V-B. Análisis del Recall Bajo y sus Causas

Un hallazgo que requiere discusión detallada es el recall relativamente bajo (0.57–0.59) de todos los modelos evaluados. Esto implica que aproximadamente el 41–43 % de los incumplimientos reales no son detectados por los modelos. Este fenómeno tiene múltiples explicaciones fundamentadas en la literatura:

1) Heterogeneidad no observada: Brown y Taylor [19] demuestran que factores como la riqueza no observada, las expectativas subjetivas y los shocks idiosincráticos introducen una varianza irreducible en la predicción del incumplimiento. El dataset UCI no incluye variables como ingresos reales, patrimonio neto ni historial crediticio completo, lo que limita la capacidad predictiva [15].




Figura 2. Evaluación del modelo base XGBoost: matriz de confusión, curva ROC (AUC = 0.7677) y curva Precision-Recall (PR-AUC = 0.5404). F1 = 0.5290, Recall = 0.5878, Accuracy = 0.7685.




Figura 3. XGBoost + GWO (15 iter, 900 OFEs). PR-AUC = 0.5535, F1 = 0.5406, Recall = 0.5750. Mejores parámetros: $n_est=360$, $depth=5$, $lr=0.046$.




Figura 4. XGBoost + GWO (30 iter, 1800 OFEs). PR-AUC = 0.5515, ROC-AUC = 0.7752, F1 = 0.5338, Recall = 0.5682. Mejores parámetros: $n_est=379$, $depth=6$, $lr=0.036$.




Figura 5. Híbrido GWO(8)+MFO(7), 900 OFEs. PR-AUC = 0.5541, ROC-AUC = 0.7755, F1 = 0.5406, Recall = 0.5750, Accuracy = 0.7838.




Figura 6. Híbrido GWO(21)+MFO(9), 1 800 OFEs. PR-AUC = 0.5507, ROC-AUC = 0.7773, F1 = 0.5434, Recall = 0.5780, Accuracy = 0.7852.




Figura 7. XGBoost + Optuna (800 trials, 900 OFEs). PR-AUC = 0.5541, ROC-AUC = 0.7772, F1 = 0.5450, Recall = 0.5818, Accuracy = 0.7852.




Figura 8. XGBoost + Optuna (1 400 trials, 1 800 OFEs). PR-AUC = 0.5543, ROC-AUC = 0.7777, F1 = 0.5444, Recall = 0.5772, Accuracy = 0.7863.

Cuadro II

COMPARATIVA DE RENDIMIENTO DE TODOS LOS MODELOS EVALUADOS. Δ PR-AUC RESPECTO AL MODELO BASE CORRESPONDIENTE. MEJORES VALORES EN NEGRITA.

Modelo	PR-AUC	ROC-AUC	F1-Score	Recall	Accuracy	Geo-Mean	Δ PR-AUC
<i>Experimento GWO-MFO (Base: PR-AUC = 0.5404)</i>							
XGBoost Base	0.5404	0.7677	0.5290	0.5878	0.7685	0.5346	—
GWO (15 Iter)	0.5535	—	0.5406	0.5750	—	—	+2.42 %
GWO (30 Iter)	0.5515	0.7752	0.5338	0.5682	0.7805	—	+2.05 %
Híbrido (8+7)	0.5541	0.7755	0.5406	0.5750	0.7838	—	+2.53 %
Híbrido (21+9)	0.5507	0.7773	0.5434	0.5780	0.7852	—	+1.91 %
<i>Experimento Optuna (Base: PR-AUC = 0.5459)</i>							
XGBoost Base	0.5459	0.7687	0.5307	0.5870	0.7703	0.5382	—
Optuna (800 Trials)	0.5541	0.7772	0.5450	0.5818	0.7852	0.5495	+1.51 %
Optuna (1 400 Trials)	0.5543	0.7777	0.5444	0.5772	0.7863	0.5494	+1.55 %

Cuadro III
MEJORES HIPERPARÁMETROS ENCONTRADOS POR CADA MÉTODO DE OPTIMIZACIÓN.

Método	n_est	depth	lr	subsample	colsample	spw
Base (fijo)	500	6	0.050	0.800	0.800	3.521
GWO (15 Iter)	360	5	0.0456	0.786	1.000	3.050
GWO (30 Iter)	379	6	0.0356	0.713	0.814	2.978
Híbrido (21+9)	323	5	0.0397	0.654	0.811	2.902
Optuna (800)	281	7	0.0167	0.642	0.810	3.120




Figura 9. Convergencia de Optuna: evolución del mejor score (Geo-Mean) en función del número de trials para los escenarios A (800) y B (1 400).

Cuadro IV
MATRICES DE CONFUSIÓN EN EL CONJUNTO DE PRUEBA ($N = 6\,000$).

Modelo	TP	FP	TN	FN
Base (GWO-MFO)	780	842	3 831	547
GWO (30 Iter)	754	744	3 929	573
Híbrido (8+7)	763	733	3 940	564
Base (Optuna)	779	830	3 843	548
Optuna (800)	772	734	3 939	555
Optuna (1 400)	766	721	3 952	561




Figura 10. Análisis de robustez: distribución de PR-AUC en 10 ejecuciones independientes (experimento GWO-MFO). Los rombos rojos indican la media.

Cuadro V
ANÁLISIS ESTADÍSTICO DE ROBUSTEZ (10 EJECUCIONES). IC: INTERVALO DE CONFIANZA DEL 95 %.

Modelo	Media	IC _{inf}	IC _{sup}	Varianza
XGBoost Base	0.5435	0.5413	0.5457	9.40e-06
GWO (15)	0.5515	0.5482	0.5547	2.05e-05
GWO (30)	0.5509	0.5472	0.5545	2.57e-05
Híbrido (8+7)	0.5502	0.5457	0.5547	3.90e-05
Híbrido (21+9)	0.5520	0.5479	0.5560	3.24e-05

2) Trade-off inherente precisión-sensibilidad: Thomas [18] documenta que los modelos de scoring crediticio rara




Figura 11. Análisis de robustez: distribución de PR-AUC en 10 ejecuciones independientes (experimento Optuna). Los rombos rojos indican la media.

Cuadro VI
TIEMPOS DE EJECUCIÓN Y PRESUPUESTO COMPUTACIONAL (OFES).

Método	Tiempo (s)	OFes
Modelo Base	1.4	N/A
GWO (15 Iter)	279.9	900
GWO (30 Iter)	604.4	1 800
Optuna (800 Trials)	390.2	900
Optuna (1 400 Trials)	941.3	1 800
Robustez GWO-MFO	15 264	–
Robustez Optuna	10 551	–

vez superan el 70 % de recall sin comprometer severamente la precisión. En nuestro caso, el modelo base presenta el recall más alto (0.5878) pero con la precisión más baja implícita ($TP/(TP+FP) = 780/1622 = 0.481$). Los modelos optimizados mejoran PR-AUC precisamente porque logran un mejor equilibrio: el Híbrido (8+7) reduce FP de 842 a 733 (−12.9 %) manteniendo TP en 763 (−2.2 %).

3) Naturaleza del desbalance: He y García [9] explican que en problemas con ratio de desbalance 3.5:1, la región de decisión óptima para la clase minoritaria es inherentemente más pequeña y compleja. Los algoritmos de boosting tienden a priorizar la clase mayoritaria en las primeras iteraciones, y aunque `scale_pos_weight` mitiga este efecto, no lo elimina completamente [1].

4) Consistencia con la literatura: Lessmann *et al.* [16] observaron recalls entre 0.45 y 0.65 en su benchmark exhaustivo, exactamente el rango de nuestros resultados. Faris *et al.* [25] reportan resultados similares con GWO aplicado a problemas de clasificación desbalanceados. Estos valores no representan

una deficiencia de nuestros métodos, sino una característica inherente del problema de scoring crediticio.

5) Implicación del umbral de decisión: Fawcett [13] señala que las métricas basadas en umbral (F1, recall, accuracy) dependen del punto de corte seleccionado (0.5 por defecto). Un análisis de umbral óptimo basado en la curva PR podría mejorar estas métricas puntuales, aunque no afectaría PR-AUC que es independiente del umbral.

V-C. La Fase MFO No Aporta Mejora Significativa

Un resultado honesto y relevante de este estudio es que la fase MFO **no produce mejora estadísticamente significativa** sobre GWO puro. Las comparaciones Híbrido (8+7) vs. GWO (15) y Híbrido (21+9) vs. GWO (30) no alcanzan significancia ($p_{\text{Holm}} > 0,21$). Las explicaciones plausibles incluyen:

- **Dimensionalidad moderada:** Con solo 6 hiperparámetros, GWO converge eficientemente sin necesidad de refinamiento adicional. El teorema *No Free Lunch* [22] sugiere que la ventaja de la hibridación se manifiesta principalmente en espacios de alta dimensionalidad.
- **Subespacio restrictivo:** El margen $\pm 20\%$ puede ser inadecuado para la trayectoria espiral de MFO [4], que requiere un espacio de exploración más amplio para su mecanismo de navegación transversal.
- **Presupuesto limitado:** 7–9 épocas de MFO (140–180 evaluaciones por fold) pueden ser insuficientes para que la espiral logarítmica converja a un óptimo local refinado.
- **Ruido en validación cruzada:** La varianza inherente de 3 pliegues puede enmascarar mejoras marginales del orden de 10^{-3} [28].

No obstante, el pipeline completo GWO+MFO sí supera significativamente al base ($p_{\text{Holm}} < 0,05$), lo que indica que la combinación es efectiva globalmente aunque la contribución marginal de MFO no sea detectable con $n = 10$.

V-D. Comparación con Trabajos Previos

La Tabla VII compara nuestros resultados con estudios previos que utilizan el mismo dataset o metodologías similares.

Nuestros resultados son consistentes con el estado del arte: el ROC-AUC de 0.7777 se sitúa en el rango superior reportado por Lessmann *et al.* [16] (0.72–0.80), y el PR-AUC de 0.5543 se encuentra en el tercil superior de su rango (0.40–0.60). La mejora sobre la configuración por defecto de XGBoost [1] (+1.55 % en PR-AUC) demuestra el valor de la optimización de hiperparámetros incluso para algoritmos ya altamente optimizados.

V-E. Híbrido GWO–MFO vs. Optuna

Bajo presupuestos equivalentes (1 800 OFEs), Optuna (1 400 trials) supera marginalmente al Híbrido (21+9) en PR-AUC puntual (0.5543 vs. 0.5507, +0.65 %). Sin embargo, en el análisis de robustez (10 ejecuciones), el Híbrido (21+9) presenta una media ligeramente superior (0.5520 vs. 0.5530 para Optuna B). Para espacios de 6 dimensiones, las metaheurísticas son competitivas con la optimización bayesiana [29], aunque Optuna ofrece ventajas prácticas significativas: menor

complejidad de implementación, poda automática de trials no prometedores, paralelización nativa y soporte para espacios de búsqueda condicionales [5].

V-F. Limitaciones del Estudio

Se identifican las siguientes limitaciones que deben considerarse al interpretar los resultados:

- **Dataset único:** Los resultados se limitan al UCI Credit Card Default [15]. La generalización a otros contextos crediticios requiere validación adicional.
- **Tamaño de muestra estadístico:** 10 ejecuciones proporcionan potencia estadística limitada para detectar diferencias pequeñas entre métodos optimizados.
- **Umbral fijo:** F1, recall y exactitud se reportan en el umbral 0.5. Un análisis de umbral óptimo podría mejorar estas métricas [13].
- **Sin validación cruzada anidada:** La evaluación final usa un único split 80/20 [28], lo que puede introducir optimismo en las estimaciones.
- **Presupuesto no exactamente equivalente:** GWO-30 realiza 1 800 OFEs (30 épocas $\times$ 20 agentes $\times$ 3 folds) frente a 1 800 de Optuna-1 400 (600 trials $\times$ 3 folds), pero la distribución temporal de las evaluaciones difiere.

V-G. Implicaciones Prácticas

Un PR-AUC de 0.5543 implica que el modelo mantiene aproximadamente 55 % de precisión promedio al recuperar los incumplimientos a lo largo de todos los umbrales de decisión. La mejora del +1.55 % sobre el modelo base puede representar reducciones significativas de pérdidas en portafolios de gran escala: para una cartera de 100 000 clientes con 22 % de incumplimiento potencial, una mejora del 1.5 % en la detección puede representar la identificación de ≈ 330 morosos adicionales, lo que a un costo promedio de USD 5 000 por incumplimiento no detectado, equivale a USD 1.65 millones en pérdidas evitadas [17], [18].

VI. CONCLUSIONES

Este trabajo presenta un análisis comparativo exhaustivo de cinco estrategias de optimización de hiperparámetros para XGBoost en predicción de incumplimiento crediticio con datos desbalanceados (ratio 3.52:1). Los principales hallazgos son:

1. El Híbrido GWO(21)+MFO(9) alcanza el mejor PR-AUC medio en robustez (0.5520, +1.56 % sobre el base), mientras que Optuna (1 400 trials) logra el mejor PR-AUC puntual (0.5543, +1.55 %). Ambos métodos son competitivos bajo presupuestos equivalentes de 1 800 OFEs.
2. Optuna ofrece ventajas prácticas significativas en simplicidad, paralelización y poda automática, siendo recomendable como primera opción en entornos productivos.
3. La robustez se confirma con 10 ejecuciones independientes (varianzas $< 4 \times 10^{-5}$). La prueba de Wilcoxon con corrección de Holm–Bonferroni verifica significancia estadística ($p_{\text{Holm}} < 0,05$) para todos los métodos optimizados frente al base.

Cuadro VII

COMPARACIÓN CON TRABAJOS PREVIOS. PR-AUC Y ROC-AUC EN COLUMNAS SEPARADAS (NO DIRECTAMENTE COMPARABLES ENTRE SÍ [11]).

Referencia	Método	PR-AUC	ROC-AUC	Acc.	Notas
Yeh y Lien [15]	NN / SVM	–	0.78	0.82	Dataset original, sin optimización
Lessmann <i>et al.</i> [16]	41 algoritmos	0.40–0.60	0.72–0.80	0.78–0.82	Benchmark, 8 datasets
Faris <i>et al.</i> [25]	GWO + SVM	–	0.77	0.80	Feature selection con GWO
Mirjalili <i>et al.</i> [26]	GWO + MLP	–	0.79	0.81	Optimización de pesos
Chen y Guestrin [1]	XGBoost (default)	–	0.78	0.78	Configuración por defecto
Akiba <i>et al.</i> [5]	Optuna + diversos	–	–	–	Framework, sin dataset específico
Este trabajo	XGB + GWO–MFO	0.5541	0.7773	0.785	Híbrido, 1 800 OFEs
Este trabajo	XGB + Optuna	0.5543	0.7777	0.786	Bayesiano, 1 800 OFEs

- La fase MFO no aporta mejora estadísticamente significativa sobre GWO puro ($p_{\text{Holm}} > 0,21$), un resultado negativo honesto que sugiere que, para espacios de 6 dimensiones, GWO es suficiente sin refinamiento adicional.
- Las métricas absolutas (PR-AUC ≈ 0.55 , recall ≈ 0.57) son consistentes con la literatura de scoring crediticio [16], [18], reflejando la dificultad inherente del problema bajo desbalance de clases.
- El recall bajo (0.57–0.59) se explica por la heterogeneidad no observada, el trade-off inherente precisión–sensibilidad y las limitaciones del dataset, no por deficiencias en los métodos de optimización.

Trabajo futuro: (i) incorporar técnicas de sobremuestreo (SMOTE [10], ADASYN) y evaluar su impacto en PR-AUC; (ii) extender la comparación a LightGBM [31] y CatBoost [32]; (iii) implementar optimización multi-objetivo (NSGA-II) para optimizar simultáneamente PR-AUC y recall; (iv) validar en múltiples datasets crediticios para evaluar generalización; (v) explorar estrategias híbridas con márgenes adaptativos para MFO; (vi) incorporar análisis de umbral óptimo y validación cruzada anidada.

DATA AND CODE AVAILABILITY

All experimental notebooks, source code, and processed datasets generated during this study are archived in the public repository [33].

REFERENCIAS

- T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, San Francisco, CA, USA, Aug. 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
- J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Ann. Statist.*, vol. 29, no. 5, pp. 1189–1232, Oct. 2001, doi: 10.1214/aos/1013203451.
- S. Mirjalili, S. M. Mirjalili, and A. Lewis, “Grey wolf optimizer,” *Adv. Eng. Softw.*, vol. 69, pp. 46–61, Mar. 2014, doi: 10.1016/j.advengsoft.2013.12.007.
- S. Mirjalili, “Moth-flame optimization algorithm: A novel nature-inspired heuristic paradigm,” *Knowl.-Based Syst.*, vol. 89, pp. 228–249, Nov. 2015, doi: 10.1016/j.knsys.2015.07.006.
- T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, “Optuna: A next-generation hyperparameter optimization framework,” in *Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery Data Mining*, Anchorage, AK, USA, Aug. 2019, pp. 2623–2631, doi: 10.1145/3292500.3330701.
- J. Snoek, H. Larochelle, and R. P. Adams, “Practical Bayesian optimization of machine learning algorithms,” in *Proc. 25th Int. Conf. Neural Information Processing Systems (NeurIPS)*, Lake Tahoe, NV, USA, Dec. 2012, pp. 2951–2959.
- J. Bergstra and Y. Bengio, “Random search for hyper-parameter optimization,” *J. Mach. Learn. Res.*, vol. 13, no. 10, pp. 281–305, Feb. 2012.
- J. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl, “Algorithms for hyper-parameter optimization,” in *Proc. 24th Int. Conf. Neural Information Processing Systems (NeurIPS)*, Granada, Spain, Dec. 2011, pp. 2546–2554.
- H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Trans. Knowl. Data Eng.*, vol. 21, no. 9, pp. 1263–1284, Sep. 2009, doi: 10.1109/TKDE.2008.239.
- N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “SMOTE: Synthetic minority over-sampling technique,” *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, Jun. 2002, doi: 10.1613/jair.953.
- J. Davis and M. Goadrich, “The relationship between Precision–Recall and ROC curves,” in *Proc. 23rd Int. Conf. Machine Learning (ICML)*, Pittsburgh, PA, USA, Jun. 2006, pp. 233–240, doi: 10.1145/1143844.1143874.
- T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLoS ONE*, vol. 10, no. 3, p. e0118432, Mar. 2015, doi: 10.1371/journal.pone.0118432.
- T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognit. Lett.*, vol. 27, no. 8, pp. 861–874, Jun. 2006, doi: 10.1016/j.patrec.2005.10.010.
- D. M. W. Powers, “Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation,” *J. Mach. Learn. Technol.*, vol. 2, no. 1, pp. 37–63, 2011.
- I.-C. Yeh and C.-H. Lien, “The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients,” *Expert Syst. Appl.*, vol. 36, no. 2, pp. 2473–2480, Mar. 2009, doi: 10.1016/j.eswa.2007.12.020.
- S. Lessmann, B. Baesens, H.-V. Seow, and L. C. Thomas, “Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research,” *Eur. J. Oper. Res.*, vol. 247, no. 1, pp. 124–136, Nov. 2015, doi: 10.1016/j.ejor.2015.05.030.
- D. J. Hand and W. E. Henley, “Statistical classification methods in consumer credit scoring: A review,” *J. Roy. Statist. Soc. A*, vol. 160, no. 3, pp. 523–541, 1997, doi: 10.1111/1467-985X.00080.
- L. C. Thomas, “A survey of credit and behavioural scoring: Forecasting financial risk of lending to consumers,” *Int. J. Forecast.*, vol. 16, no. 2, pp. 149–172, Apr. 2000, doi: 10.1016/S0169-2070(00)00034-0.
- S. Brown and K. Taylor, “Household debt and financial assets: Evidence from Germany, Great Britain and the USA,” *J. Roy. Statist. Soc. A*, vol. 171, no. 3, pp. 615–643, 2008, doi: 10.1111/j.1467-985X.2007.00525.x.
- X.-S. Yang, *Nature-Inspired Metaheuristic Algorithms*, 2nd ed. Frome, U.K.: Luniver Press, 2010.
- C. Blum and A. Roli, “Metaheuristics in combinatorial optimization: Overview and conceptual comparison,” *ACM Comput. Surv.*, vol. 35, no. 3, pp. 268–308, Sep. 2003, doi: 10.1145/937503.937505.
- D. H. Wolpert and W. G. Macready, “No free lunch theorems for optimization,” *IEEE Trans. Evol. Comput.*, vol. 1, no. 1, pp. 67–82, Apr. 1997, doi: 10.1109/4235.585893.
- J. Kennedy and R. Eberhart, “Particle swarm optimization,” in *Proc. IEEE Int. Conf. Neural Networks (ICNN)*, Perth, WA, Australia, Nov./Dec. 1995, pp. 1942–1948, doi: 10.1109/ICNN.1995.488968.
- M. Dorigo, V. Maniezzo, and A. Colomi, “Ant system: Optimization by a colony of cooperating agents,” *IEEE Trans. Syst., Man, Cybern. B*, vol. 26, no. 1, pp. 29–41, Feb. 1996, doi: 10.1109/3477.484436.

- [25] H. Faris, I. Aljarah, M. A. Al-Betar, and S. Mirjalili, “Grey wolf optimizer: A review of recent variants and applications,” *Neural Comput. Appl.*, vol. 30, no. 2, pp. 413–435, Jul. 2018, doi: 10.1007/s00521-017-3272-5.
- [26] S. Mirjalili, S. M. Mirjalili, and S. Saremi, “A review on grey wolf optimizer and its applications in computational intelligence,” in *Advances in Swarm Intelligence*, Y. Tan, Ed. Cham, Switzerland: Springer, 2017, pp. 125–135.
- [27] F. Wilcoxon, “Individual comparisons by ranking methods,” *Biom. Bull.*, vol. 1, no. 6, pp. 80–83, Dec. 1945, doi: 10.2307/3001968.
- [28] J. Demšar, “Statistical comparisons of classifiers over multiple data sets,” *J. Mach. Learn. Res.*, vol. 7, pp. 1–30, Jan. 2006.
- [29] F. Hutter, H. H. Hoos, and K. Leyton-Brown, “Sequential model-based optimization for general algorithm configuration,” in *Proc. 5th Int. Conf. Learning and Intelligent Optimization (LION)*, Rome, Italy, Jan. 2011, pp. 507–523, doi: 10.1007/978-3-642-25566-3_40.
- [30] Basel Committee on Banking Supervision, “Basel III: Finalising post-crisis reforms,” Bank for International Settlements, Basel, Switzerland, Tech. Rep., Dec. 2017.
- [31] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM: A highly efficient gradient boosting decision tree,” in *Proc. 31st Int. Conf. Neural Information Processing Systems (NeurIPS)*, Long Beach, CA, USA, Dec. 2017, pp. 3146–3154.
- [32] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, “CatBoost: Unbiased boosting with categorical features,” in *Proc. 32nd Int. Conf. Neural Information Processing Systems (NeurIPS)*, Montréal, QC, Canada, Dec. 2018, pp. 6638–6648.
- [33] L. F. López-Cabrera, J. M. Camacho-Monar, B. G. Cárdenas-Medina, D. A. Becerra-Gavidia, and D. I. Sánchez-Palomo, “Hybrid GWO–MFO and Bayesian optimization of XGBoost for credit default prediction,” *GitHub repository*, 2026. [Online]. Available: <https://github.com/Mario-Unach/IF-Metaheuristica>